

Beschrijvende analyse op statische data van de TEDx Kaggle dataset - Patty Sausele 1146363

```
import psycpg2
import pandas as pd
import numpy as np
import plotly.express as px
import seaborn as sns
import matplotlib.pyplot as plt

conn = psycpg2.connect(
    host="95.217.3.61",
    database="indatad_s1146363",
    user="s1146363",
    password="s1146363"
)

query = "SELECT v.video_id, v.titel, p.aantal_views,
p.aantal_reacties, p.aantal_likes, v.uploaddatum FROM
public.populariteit p JOIN public.video v ON p.video_id = v.video_id;"

df = pd.read_sql(query, conn)

conn.close()

C:\Users\School\AppData\Local\Temp\ipykernel_11992\837654737.py:10:
UserWarning: pandas only supports SQLAlchemy connectable
(engine/connection) or database string URI or sqlite3 DBAPI2
connection. Other DBAPI2 objects are not tested. Please consider using
SQLAlchemy.
    df = pd.read_sql(query, conn)

df.head()
```

	video_id	titel	
0	9EBkS2kE7uk	"A Seat at the Table" Isn't the Solution for G...	
1	KKNCiRWd_j0	What Is an AI Anyway? Mustafa Suleyman TED	
2	4R7mX6pChSA	How Regenerative Agriculture Brings Life Back ...	
3	sgFq4ty8wSI	How to Be an Active Citizen and Spark Change ...	
4	0BSaph01v-U	How the James Webb Space Telescope Will Unfold...	

	aantal_views	aantal_reacties	aantal_likes	uploaddatum
0	540308	2730	0	2022-03-07
1	1676426	3288	30878	2024-04-22
2	25232	108	1135	2024-10-14
3	35509	33	882	2024-04-23
4	409014	700	11342	2022-04-25

```
df.describe()
```

	aantal_views	aantal_reacties	aantal_likes
count	1.400000e+02	140.000000	140.000000
mean	1.913145e+05	465.600000	5520.128571
std	5.835174e+05	2067.564336	26596.514684
min	5.749000e+03	0.000000	0.000000
25%	3.038050e+04	38.750000	671.500000
50%	4.628000e+04	77.500000	1089.000000
75%	1.129188e+05	207.250000	2399.250000
max	5.974551e+06	23082.000000	307422.000000


Verdeling van de data

Views

```
df['aantal_views'].describe()
```

```
count    1.400000e+02
mean     1.913145e+05
std      5.835174e+05
min      5.749000e+03
25%     3.038050e+04
50%     4.628000e+04
75%     1.129188e+05
max      5.974551e+06
Name: aantal_views, dtype: float64
```


```
plt.figure(figsize=(10, 6))
plt.hist(df['aantal_views'], bins=30, color='skyblue',
edgecolor='black')
plt.title('Verdeling van het aantal views')
plt.xlabel('Aantal views')
plt.ylabel('Frequentie')
plt.grid(axis='y', alpha=0.75)
plt.show()
```



De verdeling van de views is waarschijnlijk rechtsscheef. Het gemiddelde (mean) ligt ver boven de mediaan (50%). Dit suggereert dat er enkele video's zijn die het gemiddelde omhoog trekken, omdat de meerderheid ver onder het gemiddelde ligt. Daarnaast is de standaarddeviatie (std) erg hoog. Dit suggereert dat er een grote spreiding is tussen de views. Tenslotte ligt het maximum (max) ver boven het gemiddelde en de mediaan, wat suggereert dat er uitschieters zijn.

```
df['uploaddatum'] = pd.to_datetime(df['uploaddatum'])
df['upload_maand'] = df['uploaddatum'].dt.month

views_per_month = df.groupby('upload_maand')
['aantal_views'].sum().reset_index()
fig = px.bar(views_per_month, x='upload_maand', y='aantal_views',
title="Views per maand")
fig.show()
```




De meerderheid van de views ligt vooral in mei (5).

Reacties

```
df['aantal_reacties'].describe()
```

```
count      140.000000
mean       465.600000
std        2067.564336
min         0.000000
25%        38.750000
50%        77.500000
75%       207.250000
max       23082.000000
Name: aantal_reacties, dtype: float64
```

```
plt.figure(figsize=(10, 6))
plt.hist(df['aantal_reacties'], bins=30, color='green',
edgecolor='black')
plt.title('Verdeling van het aantal reacties')
plt.xlabel('Aantal reacties')
plt.ylabel('Frequentie')
plt.grid(axis='y', alpha=0.75)
plt.show()
```



Dit is een soortgelijk verhaal met de views. Er is hoogstwaarschijnlijk sprake van een rechtsscheve verdeling. Het gemiddelde (mean) ligt ver boven de mediaan (50%). Dit suggereert dat er enkele video's zijn die het gemiddelde omhoog trekken, omdat de meerderheid ver onder het gemiddelde ligt. Daarnaast is de standaarddeviatie (std) erg hoog. Dit suggereert dat er een grote spreiding is tussen de views. Tenslotte ligt het maximum (max) ver boven het gemiddelde en de mediaan, wat suggereert dat er uitschieters zijn.


Likes

```
df['aantal_likes'].describe()
```

```
count      140.000000
mean       5520.128571
std        26596.514684
min         0.000000
25%        671.500000
50%       1089.000000
75%       2399.250000
max       307422.000000
Name: aantal_likes, dtype: float64
```

```
plt.figure(figsize=(10, 6))
plt.hist(df['aantal_likes'], bins=30, color='orange',
edgecolor='black')
plt.title('Verdeling van het aantal likes')
plt.xlabel('Aantal likes')
plt.ylabel('Frequentie')
```

```
plt.grid(axis='y', alpha=0.75)  
plt.show()
```



Wederom is dit een soortgelijk verhaal met de views en reacties. Er is hoogstwaarschijnlijk sprake van een rechtsscheve verdeling. Het gemiddelde (mean) ligt ver boven de mediaan (50%). Dit suggereert dat er enkele video's zijn die het gemiddelde omhoog trekken, omdat de meerderheid ver onder het gemiddelde ligt. Daarnaast is de standaarddeviatie (std) erg hoog. Dit suggereert dat er een grote spreiding is tussen de views. Tenslotte ligt het maximum (max) ver boven het gemiddelde en de mediaan, wat suggereert dat er uitschieters zijn.

Conclusie

De maand waarin video's het meest gekeken werden is de maand mei (5). De verdeling van de numerieke data (reacties, likes en views) is allemaal waarschijnlijk rechtsscheef met enkele uitschieters, wat betekent dat er enkele video's zijn met een grote hoeveelheid reacties, likes en views. In mijn clusteranalyse zal ik de uitschieters buiten beschouwing laten en proberen te analyseren welke variabelen invloed hebben op de populariteit van een video.