

Sterschema


INDATAD Deel 1

21-07-2025

Patty Sausele s1146363

Sterschema

Het sterschema is een weergave van de opzet van de database. Door de opdracht heen is deze continue aangepast en veranderd. Aan de hand van gekregen feedback, wordt nu het nieuwe sterschema weergegeven en toegelicht.



Er is een feitentabel, videopopulariteit, en de dimensietabellen die alle statistische data bevatten van de video's.

Dimensietabel: video

De dimensietabel is de tabel die vooral de video's zelf beschrijft.

- Bevat alle statische informatie over de video's
- Belangrijkste attributen:
 - Unieke identificatie (video_key, video_id)
 - Contentgegevens (titel, transcript)
 - Basisstatistieken (views, likes, comment_count)
 - Technische details (duur_in_seconden)

In eerste instantie stonden likes, comment_count en views in de feitentabel, maar ik heb ervoor gekozen om deze naar de dimensietabel te doen. In deze dimensietabel staat alle statistische informatie, waar deze drie waarden ook onder vallen. In plaats van deze in de feitentabel staan

daar nu nieuwe elementen die meer van toepassing zijn op het onderzoeken van de populariteit van een video.

Dimensietabel: tijd

Tijdsdimensie is wellicht nodig als je wil kijken naar aantal views in een periode. Dit is nodig als je wil bepalen of iets populair is of niet, aangezien er bijvoorbeeld meer views zullen zijn in de zomerperiode versus de lenteperiode. Door rekening te houden met seizoenen en dagen in de week, kun je een betere schatting maken van hoeveel views er per dag zijn en vergelijken of iets populair is of niet. Er is sprake van een hiërarchische tijdsindeling van jaar, maand en dag.

Dimensietabel: categorie

De dimensietabel van categorieën is nieuw. Deze is toegevoegd na aanvullend onderzoek van de populariteit van video's. Als je kijkt naar de populariteit in een categorie, is het handig om een dimensietabel te hebben van categorieën. Zo zou een video bijvoorbeeld drie miljoen views kunnen hebben en populair lijken over het algemeen, maar als deze video in een categorie zit waar een gemiddelde video twaalf miljoen views krijgt, is het nog de vraag of deze video werkelijk wel populair is.

Feitentabel: videopopulariteit

De feitentabel heeft een aantal aanpassingen gehad na feedback en onderzoek. Dit is de centrale tabel die alle meetbare gegevens en metrics bevat:

1. Keys

- video_key (verwijst naar dim_video)
- tijd_key (verwijst naar dim_tijd)
- categorie_key (verwijst naar dim_categorie)

2. Prestatiemetrieken

- views_per_day: Gemiddeld aantal views per dag
- engagement_ratio: Verhouding tussen interacties en views
- views_relative_to_category: Prestatie ten opzichte van categorie
- comment_like_ratio: Verhouding tussen comments en likes

3. Analytische Inzichten

- sentiment: Sentiment analyse resultaat
- rating: Populariteitsclassificatie
- views_growth_rate: Groeisnelheid van views
- likes_growth_rate: Groeisnelheid van likes

4. Metadata

- `last_update`: Timestamp van laatste update van de database

De persoon die mij feedback gaf, gaf aan dat het belangrijk was om de groei in views en likes bij te houden. Dit heb ik daarom toegevoegd samen met de *last_update*, zodat er op het dashboard gekeken kan worden naar wanneer de database voor het laatst geupdate is. Daarnaast zijn de prestatie metriecken: *views_per_day*, *views_relative_to_category* en *comment_like_ratio* toegevoegd voor het gedetailleerder kunnen onderzoeken van de populariteit van een video. Engagement_ratio stond er al in, maar bij nader inzien vond ik deze op zichzelf niet genoeg om de populariteit te onderzoeken.